Psy i koty

... czyli klasyfikacja obrazów i manipulacja dużą ilością danych

Karolina Kotlowska

13.1. Pobieramy dane

Załadujemy zbiór danych z kolekcji <u>TensorFlow Datasets (https://www.tensorflow.org/datasets)</u>. Zbiór jest widoczny jako obiekt klasy tf.data.Dataset zapewniającej funkcjonalność podobną do strumieni.

Przy pierwszym uruchomieniu dane zostaną pobrane. Później będzie można je czytać wielokrotnie.

In [5]:

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
import tensorflow_datasets as tfds

# setattr(tfds.image_classification.cats_vs_dogs, '_URL', "https://download.micro
soft.com/download/3/E/1/3E1C3F21-ECDB-4869-8368-6DEBA77B919F/kagglecatsanddogs_5
340.zip")
ds = tfds.load('cats_vs_dogs', split='train', batch_size=None,as_supervised=Tru
e)
```

Liczba obrazów to:

```
In [6]:
```

```
len(ds)
```

Out[6]:


23262

13.1.1 Wyświetlmy przykładowe obrazy

Przed wyświetleniem zostaną przeskalowane do tych samych rozmiarów

In [7]:

```
plt.rcParams["figure.figsize"] = (10,10)
it = ds.as_numpy_iterator()
labels=['Cat','Dog']
input_size=100
for i in range(9):
    ax = plt.subplot(330 + 1 + i)
    image, label = next(it)
    image = tf.image.resize(image, size=[256,256], method=tf.image.ResizeMethod.NE
AREST_NEIGHBOR)
    ax.set_title(labels[label])
    plt.imshow(image)
plt.show()
```



13.1.2 Załadujemy obrazy i zapiszemy w tablicach numpy

Obraz jest trójwymiarową tablicą (szerokość, wysokość, kanały koloru). Aby umieścić wszystkie obrazy w jednej tablicy 4D musza mieć identyczne rozmiary.

In [8]:

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
import tensorflow datasets as tfds
# from keras.preprocessing.image import img to array
from tensorflow.keras.utils import img to array
from tqdm import tqdm
def load images to numpy(name, resize_to=[80,80]):
 ds = tfds.load(name, split='train', batch size=None, as supervised=True)
  images = []
  labels=[]
  for image, label in tqdm(ds):
    image = tf.image.resize(image, size=resize_to, method=tf.image.ResizeMethod.
NEAREST NEIGHBOR)
    image = img_to_array(image)/255
    images.append(image)
    labels.append(label.numpy())
 # return images,labels
 X=np.array(images)
 y=np.array(labels)
 return X,y
X,y = load images to numpy('cats vs dogs')
print(X.shape)
print(y.shape)
             23262/23262 [00:58<00:00, 400.21it/s]
```

```
100% | 23262/23262 [00:58<00:00, 400.21it/s (23262, 80, 80, 3) (23262,)
```

In [9]:

plt.imshow(X[0]);



13.2. Klasyfikacja zbioru załadowanego do pamięci

Wypróbujemy kilka klasyfiaktorów z biblioteki sklearn. Przedtem musimy spłaszczyć X do postaci dwuwymiarowej tablicy.

Nie oczekujemy tu dobrych wyników, ponieważ standardowe algorytmy traktują obraz, jak długi wektor pikeseli, a nie biorą pod uwagę cech lokalnych.

Gdyby przeskalować obraz do rozmiarów 4x4 otrzymalibyśmy informacje o kolorach w różnych regionach obrazu. Może pozwoliłoby to odróżnić krajobraz morski i lądowy, ale nie psy i koty.

```
In [10]:
```

```
X = np.reshape(X,(X.shape[0],-1))
print(X.shape)
```

(23262, 19200)

TODO 13.2.1

- Wypróbuj wpierw GaussianNB, a potem co najmniej 3 wybrane kolejne klasyfikatory
- · Jaka jest efektywność klasyfikacji?
- · Co się dzieje z pamięcią
- Zestaw informacje w postaci tabeli

In [11]:

```
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB
from sklearn.naive bayes import MultinomialNB
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.linear model import SGDClassifier
from sklearn.svm import SVC
import sklearn
clf = GaussianNB()
# clf = RandomForestClassifier(n estimators=100, verbose=1)
# clf = MultinomialNB()
# clf = LogisticRegression()
# clf = KNeighborsClassifier(n neighbors=5) #umieszcza wszystkie dane w pamięci
- zużywa bardzo pamieć
# clf = SGDClassifier(loss='log')
# clf = SVC(kernel='rbf', gamma='auto')
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.1, rando
m_state = 123)
clf.fit(X_train,y_train)
y pred = clf.predict(X test)
print(f'Accuracy:{sklearn.metrics.accuracy_score(y_test,y_pred)}')
print(f'F1:{sklearn.metrics.f1_score(y_test,y_pred,average="macro")}')
```

Accuracy: 0.5612376450365277 F1: 0.5605205089886541

```
In [12]:
```

```
clf = RandomForestClassifier(n estimators=100,verbose=1)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.1, rando
m state = 123)
clf.fit(X_train,y_train)
y pred = clf.predict(X test)
print(f'Accuracy:{sklearn.metrics.accuracy_score(y_test,y_pred)}')
print(f'F1:{sklearn.metrics.f1_score(y_test,y_pred,average="macro")}')
[Parallel(n_jobs=1)]: Using backend SequentialBackend with 1 concurr
ent workers.
[Parallel(n jobs=1)]: Done 100 out of 100 | elapsed: 4.5min finishe
[Parallel(n jobs=1)]: Using backend SequentialBackend with 1 concurr
ent workers.
Accuracy: 0.6403094112591319
F1:0.6396961880884169
[Parallel(n jobs=1)]: Done 100 out of 100 | elapsed:
                                                        0.3s finishe
In [13]:
clf = LogisticRegression()
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.1, rando
m state = 123)
clf.fit(X_train,y_train)
y_pred = clf.predict(X_test)
print(f'Accuracy:{sklearn.metrics.accuracy_score(y_test,y_pred)}')
print(f'F1:{sklearn.metrics.f1 score(y test,y pred,average="macro")}')
c:\Users\krzyc\anaconda3-1\lib\site-packages\sklearn\linear model\ 1
ogistic.py:814: ConvergenceWarning: lbfgs failed to converge (status
=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
Increase the number of iterations (max iter) or scale the data as sh
own in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver option
    https://scikit-learn.org/stable/modules/linear model.html#logist
ic-regression
  n_iter_i = _check_optimize_result(
Accuracy: 0.5762784701332188
F1:0.5762608630130106
```

In [14]:

```
clf = KNeighborsClassifier(n_neighbors=5)

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.1, rando
m_state = 123)
clf.fit(X_train,y_train)
y_pred = clf.predict(X_test)
print(f'Accuracy:{sklearn.metrics.accuracy_score(y_test,y_pred)}')
print(f'F1:{sklearn.metrics.f1_score(y_test,y_pred,average="macro")}')
```

Accuracy: 0.5487752470992694 F1: 0.5253455952630719

Najlepiej sprawdził się RandomForestClassifier.

Trenowanie pochłonęło sporo pamięci. KNeighborsClassifier umieszcza wszystkie dane w pamięci - zużywa bardzo pamięć.

Model	Accuracy	F1
GaussianNB	0.5612376	0.5605205
RandomForestClassifier	0.6438633	0.6330582
LogisticRegression	0.5758487	0.5758108
KNeighborsClassifier	0.5487752	0.5253456

13.3. Partial fit

Zbiór wszystkich obrazów załadowany do pamięci zużywa około 30% pamięci środowiska Colab. Wydzielenie X_train i X_test to kolejne 30%. W przypadku niektórych klasyfikatorów brak jest miejsca na model...

W przypadku dużych zbiorów danych rozwiązanie może polegać na wykonaniu pętli, w której

- odczytuje się fragment danych (batch) ze źródła
- dane te są uzyte do uczenia (uaktualnienia modelu)

W biblotece sklearn wybrane klasyfikatory i algorytmy regresji mają służącą do tego metodę partial_fit().

13.3.1 Organizacja odczytu danych

- Obrazy będą czytane z dysku
- Podczas odczytu dokonywana będzie konwersja za pomocą funkcji img_convert

In [15]:

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
import tensorflow datasets as tfds
# from keras.preprocessing.image import img to array
from tensorflow.keras.utils import img to array
from tqdm import tqdm
dataset = tfds.load('cats vs dogs', split='train', batch size=None, as supervised
=True)
def img_convert(image, label):
  image = tf.image.resize(image, size=[80,80], method=tf.image.ResizeMethod.NEAR
EST_NEIGHBOR)
 image = image / 255
  return (image, label)
dataset = dataset.map(img_convert)
dataset = dataset.shuffle(buffer_size=100)
```

13.3.2 Podział na strumień danych uczących i testowych

Jest to podział sztywny. Funkcje take() i skip() przesuwają granice iteracji, ale nie zapewniają losowego wyboru.

Strumień (dataset) może losowo zmieniać kolejność danych, ale stosując bufor wewnętrzny o pewnym zadanym rozmiarze.

In [16]:

```
train_size = int(0.7*len(dataset))

ds_train = dataset.take(train_size)
ds_test = dataset.skip(train_size)
print(len(ds_train),len(ds_test))

ds_test = ds_test.batch(256, drop_remainder=False)
ds_train = ds_train.batch(128, drop_remainder=False)
```

16283 6979

13.3.3 Iteracja po danych

```
In [17]:
```

```
for batch,labels in ds_train:
    X=batch.numpy()
```

13.3.4 Opcjonalnie: zawartość dataset może zostać zwielokrotniona

Można wówczas wielokrotnie iterować przez te same elementy. Wielokrotna iteracja ma sens, dla modeli wyznaczanych w procesie optymalizacji (np. za pomocą metod gradientowych.) Wówczas przy równoczensym zastosowaniu losowania możliwe jest opuszczenie minimum lokalnego funkcji kosztu.

```
In [18]:
```

```
epochs=2
ds_train=ds_train.repeat(epochs)
```

13.3.5 Klasyfikacja

TODO 13.3.1

- Proszę wyznaczyć X na podstawie danych w zmiennej batch oraz y na podstawie labels. X nalezy spłaszczyć do tablicy 2-wymiarowej.
- Dla których (poniższych klasyfikatorów) wielokrotne przetwarzanie ('ogladanie') tych samych danych danych może mieć sens?
- Wypróbuj i porównaj **dwa klasyfikatory** implementujące metodę partial_fit(). Jaka jest ich efektywność?

In [19]:

```
from sklearn.naive_bayes import MultinomialNB
from sklearn.naive_bayes import GaussianNB
from sklearn.linear_model import SGDClassifier
from sklearn.linear model import PassiveAggressiveClassifier
from tqdm import tqdm
import sklearn
# clf = MultinomialNB()
# clf = GaussianNB()
# clf = PassiveAggressiveClassifier()
clf = SGDClassifier(loss='perceptron')
# for i,(batch,labels) in tqdm( enumerate(ds train) ):
for i,(batch,labels) in enumerate(ds train) :
 X=batch.numpy()
 X = np.reshape(X, (X.shape[0], -1))
 y=labels.numpy()
 clf.partial_fit(X,y,classes=[0,1])
# predict
y_true_list = []
y_pred_list = []
for i, (batch, labels) in enumerate(ds test):
    X = batch.numpy()
    X = np.reshape(X, (X.shape[0], -1))
    y = labels.numpy()
    y pred = clf.predict(X)
    y_true_list.extend(y.tolist())
    y pred list.extend(y pred.tolist())
y_true = np.hstack(y_true_list)
# y true.shape
y pred=np.hstack(y pred list)
# y pred.shape
print(f'Accuracy:{sklearn.metrics.accuracy_score(y_true,y_pred)}')
print(f'F1:{sklearn.metrics.f1_score(y_true,y_pred,average="macro")}')
print(f'auroc:{sklearn.metrics.roc auc score(y true,y pred,average="macro")}')
```

Accuracy: 0.5929216220088838 F1: 0.5900312108139593 auroc: 0.5932807726421603

In [20]:

```
clf = MultinomialNB()
# for i,(batch,labels) in tqdm( enumerate(ds train) ):
for i,(batch,labels) in enumerate(ds train) :
  X=batch.numpy()
  X = np.reshape(X, (X.shape[0], -1))
  y=labels.numpy()
  clf.partial_fit(X,y,classes=[0,1])
# predict
y_true_list = []
y pred list = []
for i, (batch, labels) in enumerate(ds_test):
    X = batch.numpy()
    X = np.reshape(X, (X.shape[0], -1))
    y = labels.numpy()
    y pred = clf.predict(X)
    y_true_list.extend(y.tolist())
    y pred list.extend(y pred.tolist())
y_true = np.hstack(y_true_list)
# y true.shape
y pred=np.hstack(y pred list)
# y pred.shape
print(f'Accuracy:{sklearn.metrics.accuracy_score(y_true,y_pred)}')
print(f'F1:{sklearn.metrics.f1 score(y true,y pred,average="macro")}')
print(f'auroc:{sklearn.metrics.roc_auc_score(y_true,y_pred,average="macro")}')
```

Accuracy: 0.5601088981229403 F1: 0.5600167487263904 auroc: 0.5600504061002419

In [21]:

```
clf = PassiveAggressiveClassifier()
# for i,(batch,labels) in tqdm( enumerate(ds train) ):
for i,(batch,labels) in enumerate(ds train) :
  X=batch.numpy()
  X = np.reshape(X, (X.shape[0], -1))
  y=labels.numpy()
  clf.partial_fit(X,y,classes=[0,1])
# predict
y_true_list = []
y pred list = []
for i, (batch, labels) in enumerate(ds_test):
    X = batch.numpy()
    X = np.reshape(X, (X.shape[0], -1))
    y = labels.numpy()
    y pred = clf.predict(X)
    y_true_list.extend(y.tolist())
    y pred list.extend(y pred.tolist())
y_true = np.hstack(y_true_list)
# y true.shape
y pred=np.hstack(y pred list)
# y pred.shape
print(f'Accuracy:{sklearn.metrics.accuracy_score(y_true,y_pred)}')
print(f'F1:{sklearn.metrics.f1 score(y true,y pred,average="macro")}')
print(f'auroc:{sklearn.metrics.roc_auc_score(y_true,y_pred,average="macro")}')
```

Accuracy: 0.5406218655967904 F1: 0.46612554829406794 auroc: 0.5420751471613843

Porównanie klasyfikatorów:

Model	Accuracy	F1 Score	AUROC
SGDClassifier	0.5002	0.3390	0.5020
MultinomialNB	0.5597	0.5596	0.5596
PassiveAggressiveClassifier	0.5406	0.4661	5420

13.3.6 Sprawdźmy metryki dla zbioru uczącego

```
In [22]:
y_true_list=[]
y pred list=[]
for i,(batch,labels) in enumerate(ds_train):
  X=batch.numpy()
  X = np.reshape(X, (X.shape[0], -1))
  y=labels.numpy()
  y_pred = clf.predict(X)
  y true list.append(y)
  y_pred_list.append(y_pred)
y_true = np.hstack(y_true_list)
# y true.shape
y_pred=np.hstack(y_pred_list)
y_pred.shape
print(f'Accuracy:{sklearn.metrics.accuracy_score(y_true,y_pred)}')
print(f'F1:{sklearn.metrics.f1_score(y_true,y_pred,average="macro")}')
print(f'auroc:{sklearn.metrics.roc_auc_score(y_true,y_pred,average="macro")}')
Accuracy: 0.5642080697660137
F1:0.49360421839379365
auroc:0.5645985227193009
In [23]:
from sklearn.metrics import confusion_matrix
conf_mat = confusion_matrix(y_true, y_pred)
print(conf_mat)
[[ 3107 13193]
    999 15267]]
```

13.4. Sieć neuronowa

Zbudujemy prostą sieć neuronową korzystającą z komponentów platformy TensorFlow/keras. Sieć składa się z:

- warstwy wejściowej (takiej jak rozmiary obrazu, czyli [100,100,3])
- warstwy spłaszczającej do postaci wektora [300000]
- warstwy ukrytej liczącej 100 neuronów z funkjcą aktywacji <u>relu</u> (https://en.wikipedia.org/wiki/Rectifier (neural networks))
- warstwy wyjściowej z dwoma neuronami i funkcją aktywacji softmax (https://en.wikipedia.org/wiki/Softmax function)

Liczba neuronów wyjściowych odpowiada liczbie klas. Odczytujemy z nich prawdopodobieństwo i wybieramy większe z nich.

Alternatywna konfiguracja w przypadku klasyfikacji binarnej to jeden neuron wyjściowy z funkcją aktywacji sigmoid. Przypomina to regresję logistyczną. W takim przypadku wybieramy 0 dla prawdopodobieństwa p < 0.5 oraz 1 dla p>=0.5.

Funkcją kosztu jest crossentropy - odpowiednik logloss znanej z regresji logistycznej.

Uwaga Podobnie jak zwykłe klasyfikatory - to nie jest architektura odpowiednia do klasyfikacji obrazów.

In [24]:

```
from keras.layers import Input, Dense, Flatten
from keras import Model

def model_builder(input_shape,labels_count):
   model_input = Input(input_shape)
   x= Flatten()(model_input)
   x = Dense(input_shape[1],activation = 'relu')(x)
   x = Dense(labels_count,activation='softmax')(x)
   model = Model(model_input, x, name='simple')
   model.compile(optimizer = 'adam', loss = 'sparse_categorical_crossentropy', me
trics=['accuracy'] )
   return model

model = model_builder((80,80,3),2)
```

Wyświetlmy informacje o modelu. Ma dużo parametrów, ponad 3 000 000.

Wejście ma rozmiar [None, 100, 100, 3] Podczas uczenia to None zostanie zastąpione wymiarami wsadu batch (tu 128).

In [25]:

```
from keras.utils import plot_model


model.summary()
print()
plot_model(model, show_shapes=True, show_layer_names=True, to_file='model.png')
from IPython.display import Image
Image(retina=True, filename='model.png',width = 1000, height = 1000)
```

Model: "simple"

Layer (type)	Output Shape	Param #
input_2 (InputLayer)	[(None, 80, 80, 3)]	0
flatten_1 (Flatten)	(None, 19200)	0
dense_2 (Dense)	(None, 80)	1536080
dense_3 (Dense)	(None, 2)	162

Total params: 1,536,242 Trainable params: 1,536,242 Non-trainable params: 0

Out[25]:



Uczymy sieć.

- Każda epoka to jednokrotna iteracja po zbiorze danych.
- · Podział na wsady (batch) jest automatycznie dokonywany przez strumień
- Podczas czytania batcha kolejne obrazy zostaną załadowane z dysku, przeskalowane i umieszczone w pamieci
- Mniej więcej w podobnym czasie poprzedni batch powinien być przetworzony na GPU
- Po każdej epoce następuje walidacja na zbiorze testowym. To przedłuża czas przetwarzania epoki (ale umożliwia przygotowanie wykresów)
- Niestety kazda epoka trwa około 37-38 sekund

In [26]:

history = model.fit(ds_train, epochs=20, batch_size=128,verbose=1,validation_dat
a=ds_test)

```
Epoch 1/20
472 - accuracy: 0.5412 - val_loss: 0.7275 - val_accuracy: 0.5641
Epoch 2/20
256/256 [============ ] - 20s 79ms/step - loss: 0.7
990 - accuracy: 0.5818 - val loss: 0.8316 - val accuracy: 0.5350
Epoch 3/20
256/256 [============ ] - 21s 82ms/step - loss: 0.7
135 - accuracy: 0.6109 - val_loss: 0.7920 - val_accuracy: 0.5528
Epoch 4/20
978 - accuracy: 0.6165 - val_loss: 0.6954 - val_accuracy: 0.6025
Epoch 5/20
431 - accuracy: 0.6433 - val_loss: 0.6824 - val_accuracy: 0.6075
Epoch 6/20
481 - accuracy: 0.6435 - val_loss: 0.7245 - val_accuracy: 0.5938
Epoch 7/20
256/256 [============== ] - 21s 81ms/step - loss: 0.6
282 - accuracy: 0.6550 - val loss: 0.7575 - val accuracy: 0.5777
Epoch 8/20
428 - accuracy: 0.6499 - val_loss: 0.7445 - val_accuracy: 0.5797
Epoch 9/20
256/256 [============ ] - 19s 75ms/step - loss: 0.6
239 - accuracy: 0.6563 - val_loss: 0.6400 - val_accuracy: 0.6340
Epoch 10/20
047 - accuracy: 0.6656 - val_loss: 0.6826 - val_accuracy: 0.6114
Epoch 11/20
005 - accuracy: 0.6739 - val_loss: 0.6663 - val_accuracy: 0.6161
Epoch 12/20
256/256 [============== ] - 19s 75ms/step - loss: 0.5
963 - accuracy: 0.6784 - val_loss: 0.6886 - val_accuracy: 0.6164
Epoch 13/20
256/256 [============ ] - 20s 77ms/step - loss: 0.5
793 - accuracy: 0.6915 - val_loss: 0.6927 - val_accuracy: 0.6146
Epoch 14/20
911 - accuracy: 0.6823 - val_loss: 0.7020 - val_accuracy: 0.6080
Epoch 15/20
256/256 [============== ] - 21s 80ms/step - loss: 0.5
691 - accuracy: 0.7007 - val_loss: 0.6725 - val_accuracy: 0.6207
Epoch 16/20
646 - accuracy: 0.7046 - val_loss: 0.6459 - val_accuracy: 0.6414
Epoch 17/20
256/256 [============ ] - 20s 77ms/step - loss: 0.5
543 - accuracy: 0.7131 - val_loss: 0.6516 - val_accuracy: 0.6371
Epoch 18/20
451 - accuracy: 0.7211 - val_loss: 0.7432 - val_accuracy: 0.6025
Epoch 19/20
444 - accuracy: 0.7202 - val_loss: 0.6549 - val_accuracy: 0.6383
Epoch 20/20
384 - accuracy: 0.7245 - val_loss: 0.7738 - val_accuracy: 0.5991
```

TODO 13.4.1

Wyświetl wykresy z danymi zawartymi w history


In [27]:

```
print(history.history.keys())
plt.plot(history.history['loss'])
plt.plot(history.history['val_loss'])
plt.legend()
plt.grid()
plt.show()


plt.figure()
plt.plot(history.history['accuracy'])
plt.plot(history.history['val_accuracy'])
plt.legend()
plt.grid()
plt.show()
```

WARNING:matplotlib.legend:No artists with labels found to put in leg end. Note that artists whose label start with an underscore are ign ored when legend() is called with no argument.

dict_keys(['loss', 'accuracy', 'val_loss', 'val_accuracy'])



WARNING:matplotlib.legend:No artists with labels found to put in leg end. Note that artists whose label start with an underscore are ign ored when legend() is called with no argument.



13.5. Zbiór danych w pamieci

Spróbujemy przetwarzać zbiór danych w pamięci. To powinno przyspieszyć. Colab ma słabe CPU i kod wykonywany po stronie hosta działa wolno.

Zresetuj środowisko wykonawcze

13.5.1 Funkcja ładująca zbiór danych do macierzy numpy


In [2]:

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
import tensorflow_datasets as tfds
from tensorflow.keras.utils import img to array
from tqdm import tqdm
def load_images_to_numpy(name,resize_to=[80,80]):
 ds = tfds.load('cats_vs_dogs', split='train', batch_size=None,as_supervised=Tr
ue)
  images = []
  labels=[]
  for image, label in tqdm(ds):
    image = tf.image.resize(image, size=resize_to, method=tf.image.ResizeMethod.
NEAREST_NEIGHBOR)
    image = img_to_array(image)/255
    images.append(image)
    labels.append(label.numpy())
 # return images,labels
 X=np.array(images)
 y=np.array(labels)
 return X,y
```

In [3]:

```
X,y = load_images_to_numpy('cats_vs_dogs')
plt.imshow(X[0]);
```

100% | 23262/23262 [00:50<00:00, 460.19it/s]



13.5.2 Sprawdzamy ile mamy pamięci

In [4]:

```
import psutil
psutil.virtual_memory()
```

Out[4]:

svmem(total=16977661952, available=2503389184, percent=85.3, used=14
474272768, free=2503389184)

13.5.3 Duża monolityczna funkcja do ucznia modeli i ich oceny

Napiszemy funkcję, która:

- 1. Wydzieli zbiór uczący i testowy
- 2. Wywoła zewnętrzną funkcję do budowy modelu
- 3. Przeprowadzi uczenie z walidacją
- 4. Przetestuje model na zbiorze testowym
- 5. Wypisze metryki

TODO 13.5.1

- Ad 1. Podziel dane w proporcjach określonych przez test_size za pomocą train_test_split
- · Ad 3. Wywołaj model.fit
- · Ad 3. Wyświetl historię
- Ad 4. Wyznacz przewidywane etykiety y_pred
- · Ad 5. Oblicz metryki

In [5]:

```
from sklearn.model selection import train test split
from sklearn.metrics import accuracy score, precision score, recall score, f1 sc
import matplotlib.pyplot as plt
import psutil
def split train test(X, y, model builder, epochs=20, test size=0.3, batch size=1
28, use_validation_data=True, display_history=True):
    print(psutil.virtual_memory())
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=test_siz
e)
    ds train = tf.data.Dataset.from tensor slices((X train, y train)).shuffle(10
00)
    ds train = ds train.batch(batch size, drop remainder=True)
    ds_test = tf.data.Dataset.from_tensor_slices((X_test, y_test))
    ds_test = ds_test.batch(batch_size)
    model = model builder()
    validation data = None
    if use validation data:
        validation_data = ds_test
    history = model.fit(ds_train, epochs=epochs, validation_data=validation_dat
a)
    if display_history:
        print(history.history.keys())
        plt.plot(history.history['loss'])
        plt.plot(history.history['val_loss'])
        plt.legend()
        plt.grid()
        plt.show()
        plt.figure()
        plt.plot(history.history['accuracy'])
        plt.plot(history.history['val_accuracy'])
        plt.legend()
        plt.grid()
        plt.show()
    ds_test = tf.data.Dataset.from_tensor_slices((X_test, y_test))
    ds test = ds test.batch(128, drop remainder=False)
    predict_proba = model.predict(ds_test)
    print(predict_proba.shape)
    y pred = np.argmax(predict proba, axis=1)
    acc = accuracy score(y_test, y_pred)
    prec = precision score(y test, y pred, average='macro')
    recall = recall_score(y_test, y_pred, average='macro')
    f1 = f1_score(y_test, y_pred, average='macro')
    print(f'acc={acc}')
    print(f'prec={prec}')
    print(f'recall={recall}')
    print(f'f1={f1}')
    print(psutil.virtual_memory())
    return model
```


13.5.4 Wywołanie


```
In [32]:
```

m = split_train_test(X,y,lambda: model_builder((80,80,3),2))


```
svmem(total=16977661952, available=4780638208, percent=71.8, used=12
197023744, free=4780638208)
Epoch 1/20
14 - accuracy: 0.5487 - val_loss: 0.6759 - val_accuracy: 0.5809
127/127 [============= ] - 4s 32ms/step - loss: 0.67
49 - accuracy: 0.5830 - val_loss: 0.6807 - val_accuracy: 0.5731
Epoch 3/20
79 - accuracy: 0.5909 - val_loss: 0.6837 - val_accuracy: 0.5676
Epoch 4/20
48 - accuracy: 0.6009 - val loss: 0.6603 - val accuracy: 0.6002
Epoch 5/20
127/127 [============] - 4s 29ms/step - loss: 0.67
64 - accuracy: 0.5893 - val_loss: 0.6936 - val_accuracy: 0.5584
Epoch 6/20
127/127 [============ ] - 4s 30ms/step - loss: 0.65
40 - accuracy: 0.6175 - val loss: 0.6603 - val accuracy: 0.5999
Epoch 7/20
127/127 [============] - 4s 34ms/step - loss: 0.65
80 - accuracy: 0.6059 - val_loss: 0.6712 - val_accuracy: 0.5838
Epoch 8/20
127/127 [============ ] - 3s 28ms/step - loss: 0.65
33 - accuracy: 0.6128 - val_loss: 0.6635 - val_accuracy: 0.5949
Epoch 9/20
10 - accuracy: 0.6064 - val_loss: 0.6599 - val_accuracy: 0.6004
Epoch 10/20
127/127 [============= ] - 4s 32ms/step - loss: 0.64
31 - accuracy: 0.6291 - val loss: 0.6556 - val accuracy: 0.6067
Epoch 11/20
38 - accuracy: 0.6253 - val_loss: 0.6701 - val_accuracy: 0.5838
Epoch 12/20
90 - accuracy: 0.6215 - val_loss: 0.6712 - val_accuracy: 0.5865
Epoch 13/20
42 - accuracy: 0.6243 - val_loss: 0.6574 - val_accuracy: 0.6037
Epoch 14/20
80 - accuracy: 0.6208 - val loss: 0.7139 - val accuracy: 0.5488
Epoch 15/20
127/127 [============] - 4s 32ms/step - loss: 0.64
11 - accuracy: 0.6288 - val_loss: 0.6545 - val_accuracy: 0.6098
Epoch 16/20
69 - accuracy: 0.6352 - val loss: 0.6546 - val accuracy: 0.6060
Epoch 17/20
127/127 [============] - 4s 29ms/step - loss: 0.64
38 - accuracy: 0.6266 - val_loss: 0.6569 - val_accuracy: 0.6075
Epoch 18/20
98 - accuracy: 0.6459 - val_loss: 0.6655 - val_accuracy: 0.5913
Epoch 19/20
40 - accuracy: 0.6414 - val_loss: 0.6614 - val_accuracy: 0.6074
Epoch 20/20
```

WARNING:matplotlib.legend:No artists with labels found to put in leg end. Note that artists whose label start with an underscore are ign ored when legend() is called with no argument.





WARNING:matplotlib.legend:No artists with labels found to put in leg end. Note that artists whose label start with an underscore are ign ored when legend() is called with no argument.



55/55 [===========================] - 1s 15ms/step (6979, 2) acc=0.6122653675311649 prec=0.6125414634516392 recall=0.6120915094409354 f1=0.6118024533612233 svmem(total=16977661952, available=3190104064, percent=81.2, used=13 787557888, free=3190104064)

TODO 13.5.2

- · Oceń zużycie pamięci
- Czy pamięć została zwolniona po wyjściu z funkcji?

Zużycie pamięci przed: svmem(total=16977661952, available=4780638208, percent=71.8, used=12197023744, free=4780638208)

Zużycie pamięci po:

svmem(total=16977661952, available=3190104064, percent=81.2, used=13787557888, free=3190104064)

Wyraźnie widać że procentowe zużycie pamięci znacznie wzrosło - o około 10 punktów procentowe.

Nie, pamięć nie została zwolniona po wyjściu z funkcji

13.6. Konwolucyjna sieć neuronowa CNN

- Sieci konwolucyjne automatycznie ekstrahują cechy z obrazu stosując operacje konwolucji.
- Nie posługują się ustalonymi manualnie wagami filtrów konwolucji, ale wyznaczają je w trakcie uczenia

Zaprezentowane tu modele pochodzą ze strony <u>How to Classify Photos of Dogs and Cats (with 97% accuracy) (https://machinelearningmastery.com/how-to-develop-a-convolutional-neural-network-to-classify-photos-of-dogs-and-cats/) ale zostały nieco zmodyfikowane</u>

- Rozmiary obrazów sa mniejsze (80 x 80) vs (224 x 224). Zapewne wyniki będa gorsze
- Zastosowane sa modele z dwoma neuronami wyjściowym

13.6.1 Prosty model

```
In [33]:
```

```
from keras.layers import Conv2D, Dense, Flatten, MaxPooling2D
from keras import Sequential
from keras.optimizers import SGD
from keras.applications.vgg16 import VGG16
from keras.models import Model
def define simple model():
        model = Sequential()
        model.add(Conv2D(32, (3, 3), activation='relu', kernel_initializer='he_u
niform', padding='same', input_shape=(80, 80, 3)))
        model.add(MaxPooling2D((2, 2)))
        model.add(Flatten())
        model.add(Dense(128, activation='relu', kernel initializer='he unifor
m'))
        model.add(Dense(2, activation='softmax'))
        # compile model
        model.compile(optimizer='adam', loss='sparse_categorical_crossentropy',
metrics=['accuracy'])
        return model
model = define_simple_model()
```

Inspekcja modelu

In [34]:

```
from keras.utils import plot_model


model.summary()
print()
plot_model(model, show_shapes=True, show_layer_names=True, to_file='model.png')
from IPython.display import Image
Image(retina=True, filename='model.png',width = 1000, height = 1000)
```

Model: "sequential"

conv2d (Conv2D) (None, 80, 80, 32) 896 max_pooling2d (MaxPooling2D (None, 40, 40, 32) 0) flatten_3 (Flatten) (None, 51200) 0 dense_6 (Dense) (None, 128) 6553728 dense_7 (Dense) (None, 2) 258	Layer (type)	Output Shape	Param #
flatten_3 (Flatten) (None, 51200) 0 dense_6 (Dense) (None, 128) 6553728	conv2d (Conv2D)	(None, 80, 80, 32)	896
dense_6 (Dense) (None, 128) 6553728	<pre>max_pooling2d (MaxPooling2D)</pre>	(None, 40, 40, 32)	0
(,,	flatten_3 (Flatten)	(None, 51200)	0
dense_7 (Dense) (None, 2) 258	dense_6 (Dense)	(None, 128)	6553728
	dense_7 (Dense)	(None, 2)	258
Total params: 6,554,882			

Total params: 6,554,882 Trainable params: 6,554,882 Non-trainable params: 0

Out[34]:




Uczenie i ocena


```
In [35]:
```

m = split_train_test(X,y,define_simple_model,epochs=20)


```
svmem(total=16977661952, available=4925558784, percent=71.0, used=12
052103168, free=4925558784)
Epoch 1/20
9912 - accuracy: 0.5418 - val_loss: 0.6775 - val_accuracy: 0.5466
Epoch 2/20
6510 - accuracy: 0.6125 - val loss: 0.6173 - val accuracy: 0.6550
Epoch 3/20
6054 - accuracy: 0.6676 - val_loss: 0.6045 - val_accuracy: 0.6647
Epoch 4/20
5717 - accuracy: 0.7029 - val loss: 0.5625 - val accuracy: 0.7053
5527 - accuracy: 0.7130 - val_loss: 0.5747 - val_accuracy: 0.6965
Epoch 6/20
5217 - accuracy: 0.7386 - val_loss: 0.5401 - val_accuracy: 0.7173
Epoch 7/20
4961 - accuracy: 0.7608 - val_loss: 0.5223 - val_accuracy: 0.7379
Epoch 8/20
4788 - accuracy: 0.7721 - val_loss: 0.5159 - val_accuracy: 0.7438
Epoch 9/20
4492 - accuracy: 0.7909 - val_loss: 0.5248 - val_accuracy: 0.7409
Epoch 10/20
4391 - accuracy: 0.7950 - val loss: 0.5146 - val accuracy: 0.7474
Epoch 11/20
4117 - accuracy: 0.8101 - val_loss: 0.5202 - val_accuracy: 0.7461
Epoch 12/20
4036 - accuracy: 0.8145 - val loss: 0.5376 - val accuracy: 0.7442
Epoch 13/20
3855 - accuracy: 0.8250 - val_loss: 0.5166 - val_accuracy: 0.7543
Epoch 14/20
3644 - accuracy: 0.8396 - val loss: 0.5299 - val accuracy: 0.7527
Epoch 15/20
3454 - accuracy: 0.8485 - val_loss: 0.5307 - val_accuracy: 0.7547
Epoch 16/20
3237 - accuracy: 0.8612 - val loss: 0.5512 - val accuracy: 0.7494
Epoch 17/20
3076 - accuracy: 0.8667 - val_loss: 0.5549 - val_accuracy: 0.7534
Epoch 18/20
3028 - accuracy: 0.8671 - val_loss: 0.5572 - val_accuracy: 0.7521
Epoch 19/20
2809 - accuracy: 0.8800 - val_loss: 0.5903 - val_accuracy: 0.7508
Epoch 20/20
```

WARNING:matplotlib.legend:No artists with labels found to put in leg end. Note that artists whose label start with an underscore are ign ored when legend() is called with no argument.





WARNING:matplotlib.legend:No artists with labels found to put in leg end. Note that artists whose label start with an underscore are ign ored when legend() is called with no argument.



55/55 [===================] - 6s 98ms/step (6979, 2) acc=0.7511104742799828 prec=0.7538574243172546 recall=0.7518064901397714 f1=0.7507429121935926 svmem(total=16977661952, available=4906016768, percent=71.1, used=12 071645184, free=4906016768)

13.6.2 Zaawansowany model korzystjący z tarnsfer learning

In [7]:

```
from keras.layers import Conv2D, Dense, Flatten, MaxPooling2D
from keras import Sequential
from keras.optimizers import SGD
from keras.applications.vgg16 import VGG16
from keras.models import Model
# Na podstawie
# https://machinelearningmastery.com/how-to-develop-a-convolutional-neural-netwo
rk-to-classify-photos-of-dogs-and-cats/
def define vgg16 model():
        # load model
        model = VGG16(include_top=False, input_shape=(80, 80, 3))
        # mark loaded layers as not trainable
        for layer in model.layers:
                layer.trainable = False
        # add new classifier layers
        flat1 = Flatten()(model.layers[-1].output)
        class1 = Dense(128, activation='relu', kernel initializer='he uniform')
(flat1)
        output = Dense(2, activation='softmax')(class1)
        # define new model
        model = Model(inputs=model.inputs, outputs=output)
        # compile model
        model.compile(optimizer='adam', loss='sparse_categorical_crossentropy',
metrics=['accuracy'])
        return model
model = define_vgg16_model()
```

Inspekcja modelu

In [37]:

```
from keras.utils import plot_model

model.summary()
print()
plot_model(model, show_shapes=True, show_layer_names=True, to_file='model.png')
from IPython.display import Image
Image(retina=True, filename='model.png',width = 1000, height = 1000)
```


Model: "model"


Layer (type)	Output Shape	Param #
input_4 (InputLayer)	[(None, 80, 80, 3)]	0
block1_conv1 (Conv2D)	(None, 80, 80, 64)	1792
block1_conv2 (Conv2D)	(None, 80, 80, 64)	36928
block1_pool (MaxPooling2D)	(None, 40, 40, 64)	0
block2_conv1 (Conv2D)	(None, 40, 40, 128)	73856
block2_conv2 (Conv2D)	(None, 40, 40, 128)	147584
block2_pool (MaxPooling2D)	(None, 20, 20, 128)	0
block3_conv1 (Conv2D)	(None, 20, 20, 256)	295168
block3_conv2 (Conv2D)	(None, 20, 20, 256)	590080
block3_conv3 (Conv2D)	(None, 20, 20, 256)	590080
block3_pool (MaxPooling2D)	(None, 10, 10, 256)	0
block4_conv1 (Conv2D)	(None, 10, 10, 512)	1180160
block4_conv2 (Conv2D)	(None, 10, 10, 512)	2359808
block4_conv3 (Conv2D)	(None, 10, 10, 512)	2359808
block4_pool (MaxPooling2D)	(None, 5, 5, 512)	0
block5_conv1 (Conv2D)	(None, 5, 5, 512)	2359808
block5_conv2 (Conv2D)	(None, 5, 5, 512)	2359808
block5_conv3 (Conv2D)	(None, 5, 5, 512)	2359808
block5_pool (MaxPooling2D)	(None, 2, 2, 512)	0
flatten_5 (Flatten)	(None, 2048)	0
dense_10 (Dense)	(None, 128)	262272
dense_11 (Dense)	(None, 2)	258

Total params: 14,977,218
Trainable params: 262,530

Non-trainable params: 14,714,688

Out[37]:






```
In [38]:
```

m = split_train_test(X,y,define_vgg16_model,epochs=20)


```
svmem(total=16977661952, available=6163402752, percent=63.7, used=10
814259200, free=6163402752)
Epoch 1/20
32 - accuracy: 0.7849 - val_loss: 0.3776 - val_accuracy: 0.8253
127/127 [============= ] - 341s 3s/step - loss: 0.35
46 - accuracy: 0.8401 - val_loss: 0.3559 - val_accuracy: 0.8356
Epoch 3/20
41 - accuracy: 0.8484 - val_loss: 0.3477 - val_accuracy: 0.8431
Epoch 4/20
127/127 [============= ] - 345s 3s/step - loss: 0.30
63 - accuracy: 0.8640 - val loss: 0.3430 - val accuracy: 0.8470
Epoch 5/20
127/127 [============] - 358s 3s/step - loss: 0.29
09 - accuracy: 0.8734 - val_loss: 0.3439 - val_accuracy: 0.8481
Epoch 6/20
127/127 [============= ] - 347s 3s/step - loss: 0.26
31 - accuracy: 0.8882 - val loss: 0.3580 - val accuracy: 0.8404
Epoch 7/20
127/127 [============] - 366s 3s/step - loss: 0.24
20 - accuracy: 0.8982 - val_loss: 0.3656 - val_accuracy: 0.8421
Epoch 8/20
127/127 [============ ] - 378s 3s/step - loss: 0.21
99 - accuracy: 0.9110 - val_loss: 0.3584 - val_accuracy: 0.8454
Epoch 9/20
94 - accuracy: 0.9196 - val_loss: 0.3710 - val_accuracy: 0.8431
Epoch 10/20
127/127 [============ ] - 331s 3s/step - loss: 0.17
44 - accuracy: 0.9320 - val loss: 0.3934 - val accuracy: 0.8421
Epoch 11/20
06 - accuracy: 0.9461 - val_loss: 0.3965 - val_accuracy: 0.8460
Epoch 12/20
127/127 [============= ] - 339s 3s/step - loss: 0.13
65 - accuracy: 0.9524 - val_loss: 0.4080 - val_accuracy: 0.8420
Epoch 13/20
75 - accuracy: 0.9623 - val_loss: 0.4224 - val_accuracy: 0.8457
Epoch 14/20
52 - accuracy: 0.9658 - val_loss: 0.4401 - val_accuracy: 0.8442
Epoch 15/20
127/127 [============] - 340s 3s/step - loss: 0.09
29 - accuracy: 0.9699 - val_loss: 0.4447 - val_accuracy: 0.8454
Epoch 16/20
51 - accuracy: 0.9791 - val loss: 0.4807 - val accuracy: 0.8458
Epoch 17/20
127/127 [============ ] - 339s 3s/step - loss: 0.06
75 - accuracy: 0.9816 - val_loss: 0.4840 - val_accuracy: 0.8401
Epoch 18/20
63 - accuracy: 0.9867 - val_loss: 0.5204 - val_accuracy: 0.8412
Epoch 19/20
75 - accuracy: 0.9911 - val_loss: 0.5211 - val_accuracy: 0.8379
Epoch 20/20
```

WARNING:matplotlib.legend:No artists with labels found to put in leg end. Note that artists whose label start with an underscore are ign ored when legend() is called with no argument.





WARNING:matplotlib.legend:No artists with labels found to put in leg end. Note that artists whose label start with an underscore are ign ored when legend() is called with no argument.




55/55 [===================] - 118s 2s/step (6979, 2) acc=0.8420977217366384 prec=0.8428989329964571 recall=0.8421772289162761 f1=0.8420257150979455 svmem(total=16977661952, available=2992447488, percent=82.4, used=13 985214464, free=2992447488)

13.6.3 Zobaczmy koty i psy...

In [39]:

```
ds = tfds.load('cats_vs_dogs', split='train', batch_size=None,as_supervised=Tru
e).shuffle(1000)
it = ds.as_numpy_iterator()
plt.rcParams["figure.figsize"] = (10,10)
labels=['Cat','Dog']
input size=80
for i in range(9):
  ax = plt.subplot(330 + 1 + i)
  image, label = next(it)
  image = tf.image.resize(image, size=[80,80], method=tf.image.ResizeMethod.NEAR
EST NEIGHBOR)
 batched image = tf.expand dims(image, axis=0)
  pp = m.predict(batched_image)
  c = np.argmax(pp)
  ax.set_title(labels[label]+" - predicted:"+labels[c])
  ax.imshow(image)
plt.show()
```





TODO 13.6.1

- Przeanalizuj wykresy. Ile epok wystarczyło wybrać?
- Jak zmienia się wartość funkcji kosztu i trafność dla zbioru uczącego?
- Jak scharakteryzujesz sytuację począwszy od 5-6 epoki?

Wystarczyło wybrać 5 epok.

Funkcja kosztu maleje przez cały okres trenowania sieci. Trafność dla zbioru uczącego rośnie logarytmicznie.

Od 5-6 epoki val_loss dla zbioru testowego zaczyna rosnąć. Parametr val_loss odnosi się do wartości funkcji straty obliczanej na zestawie walidacyjnym podczas procesu uczenia modelu maszynowego. Celem uczenia maszynowego jest minimalizacja funkcji straty, a więc uzyskanie malejącego parametru val_loss.

13.6.4 Twój model

TODO 13.6.2

- Wybierz jeden z modeli ze strony How to Classify Photos of Dogs and Cats (with 97% accuracy)
 (https://machinelearningmastery.com/how-to-develop-a-convolutional-neural-network-to-classify-photos-of-dogs-and-cats/)
- Dostosuj analogicznie do innej reprezentacji wyjścia (2 neurony)
- · Wyświetl strukture
- · Przeprowadź uczenie i ocenę

In [8]:

```
def define_model():
    model = Sequential()
    model.add(Conv2D(32, (3, 3), activation='relu', kernel_initializer='he_unifo
rm', padding='same', input_shape=(80, 80, 3)))
    model.add(MaxPooling2D((2, 2)))
    model.add(Flatten())
    model.add(Dense(128, activation='relu', kernel_initializer='he_uniform'))
    model.add(Dense(1, activation='sigmoid'))
    opt = SGD(lr=0.001, momentum=0.9)
    model.compile(optimizer=opt, loss='binary_crossentropy', metrics=['accurac y'])
    return model

model = define_model()
```

```
c:\Users\krzyc\anaconda3-1\lib\site-packages\keras\optimizers\optimi
zer_v2\gradient_descent.py:111: UserWarning: The `lr` argument is de
precated, use `learning_rate` instead.
   super().__init__(name, **kwargs)
```

Inspekcja modelu

In [10]:

```
from keras.utils import plot_model


model.summary()
print()
plot_model(model, show_shapes=True, show_layer_names=True, to_file='model.png')
from IPython.display import Image
Image(retina=True, filename='model.png',width = 1000, height = 1000)
```

Model: "sequential"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 80, 80, 32)	896
<pre>max_pooling2d (MaxPooling2D)</pre>	(None, 40, 40, 32)	0
flatten_1 (Flatten)	(None, 51200)	0
dense_2 (Dense)	(None, 128)	6553728
dense_3 (Dense)	(None, 1)	129
Total params: 6,554,753 Trainable params: 6,554,753		=======

Non-trainable params: 0

Out[10]:



Uczenie i ocena

TODO 13.6.3

• Porównaj złożoność wybranego modelu z innymi i skomentuj wyniki


```
In [12]:
```

m = split_train_test(X,y,define_vgg16_model,epochs=20)


```
svmem(total=16977661952, available=874242048, percent=94.9, used=161
03419904, free=874242048)
Epoch 1/20
10 - accuracy: 0.8087 - val_loss: 0.3809 - val_accuracy: 0.8281
127/127 [============= ] - 347s 3s/step - loss: 0.34
03 - accuracy: 0.8479 - val_loss: 0.3628 - val_accuracy: 0.8374
Epoch 3/20
83 - accuracy: 0.8537 - val_loss: 0.3680 - val_accuracy: 0.8339
Epoch 4/20
94 - accuracy: 0.8669 - val loss: 0.3584 - val accuracy: 0.8399
127/127 [============] - 334s 3s/step - loss: 0.27
71 - accuracy: 0.8815 - val_loss: 0.3615 - val_accuracy: 0.8407
Epoch 6/20
127/127 [============] - 333s 3s/step - loss: 0.25
71 - accuracy: 0.8920 - val loss: 0.3684 - val accuracy: 0.8369
Epoch 7/20
127/127 [============ ] - 333s 3s/step - loss: 0.24
13 - accuracy: 0.8970 - val_loss: 0.3679 - val_accuracy: 0.8394
Epoch 8/20
127/127 [============ ] - 334s 3s/step - loss: 0.20
41 - accuracy: 0.9173 - val_loss: 0.3893 - val_accuracy: 0.8325
Epoch 9/20
50 - accuracy: 0.9278 - val_loss: 0.3987 - val_accuracy: 0.8389
Epoch 10/20
127/127 [============ ] - 337s 3s/step - loss: 0.17
00 - accuracy: 0.9330 - val loss: 0.4062 - val accuracy: 0.8308
Epoch 11/20
46 - accuracy: 0.9472 - val_loss: 0.4289 - val_accuracy: 0.8269
Epoch 12/20
127/127 [============ ] - 335s 3s/step - loss: 0.11
85 - accuracy: 0.9600 - val_loss: 0.4347 - val_accuracy: 0.8319
Epoch 13/20
94 - accuracy: 0.9634 - val_loss: 0.4534 - val_accuracy: 0.8345
Epoch 14/20
71 - accuracy: 0.9733 - val loss: 0.4807 - val accuracy: 0.8319
Epoch 15/20
36 - accuracy: 0.9803 - val_loss: 0.4994 - val_accuracy: 0.8286
Epoch 16/20
16 - accuracy: 0.9852 - val loss: 0.5043 - val accuracy: 0.8335
Epoch 17/20
127/127 [============] - 341s 3s/step - loss: 0.05
27 - accuracy: 0.9880 - val_loss: 0.5334 - val_accuracy: 0.8356
Epoch 18/20
15 - accuracy: 0.9929 - val_loss: 0.5639 - val_accuracy: 0.8288
Epoch 19/20
81 - accuracy: 0.9931 - val_loss: 0.5751 - val_accuracy: 0.8331
Epoch 20/20
```

WARNING:matplotlib.legend:No artists with labels found to put in leg end. Note that artists whose label start with an underscore are ign ored when legend() is called with no argument.

dict_keys(['loss', 'accuracy', 'val_loss', 'val_accuracy'])



WARNING:matplotlib.legend:No artists with labels found to put in leg end. Note that artists whose label start with an underscore are ign ored when legend() is called with no argument.



55/55 [=============] - 101s 2s/step (6979, 2) acc=0.831494483450351 prec=0.8318805726689342 recall=0.8316826730692277 f1=0.8314840174660438 symem(total=16977661952, available=2973536256, percent=82.5, used=14 004125696, free=2973536256)

In []:

```
ds = tfds.load('cats_vs_dogs', split='train', batch_size=None,as_supervised=Tru
e).shuffle(1000)
it = ds.as_numpy_iterator()
plt.rcParams["figure.figsize"] = (10,10)
labels=['Cat','Dog']
input_size=100
for i in range(9):
 ax = plt.subplot(330 + 1 + i)
  image, label = next(it)
  image = tf.image.resize(image, size=[100,100], method=tf.image.ResizeMethod.NE
AREST NEIGHBOR)
 batched image = tf.expand dims(image, axis=0)
 pp = m.predict(batched image)
 c = np.argmax(pp)
 ax.set_title(labels[label]+" - predicted:"+labels[c])
  ax.imshow(image)
plt.show()
```

Porównanie trzech ostatnich modeli w tym notatniku

Model 1:

Liczba warstw konwolucyjnych: 1 Liczba warstw poolingowych: 1 Liczba warstw gęstych: 2 Całkowita liczba warstw: 6

Model 2:

Liczba warstw konwolucyjnych: 1 Liczba warstw poolingowych: 1 Liczba warstw gęstych: 1 Liczba warstw wyjściowych: 1 Całkowita liczba warstw: 5

Model 3:

Liczba warstw konwolucyjnych: 1 Liczba warstw poolingowych: 1 Liczba warstw gęstych: 2 Liczba warstw wyjściowych: 1 Całkowita liczba warstw: 6