SPRAWOZDANIE - LABORATORIUM 5

Karolina Kotłowska, 9 kwietnia 2023

5.1

java -cp Weka-3-8/weka.jar weka.core.converters.CSVLoader egzamin-cpp.csv
-S 1 -F ; -D 3 -format yyyy-mm-dd > egzamin-cpp-train.arff

java -cp Weka-3-8/weka.jar weka.core.converters.CSVLoader egzamin-cpp-train.csv -S 1 -F ; -D 3 -format yyyy-mm-dd > egzamin-cpp-train.arff

java -cp Weka-3-8/weka.jar weka.core.converters.CSVLoader egzamin-cpp-test.csv -S 1 -F ; -D 3 -N 5 -format yyyy-mm-dd > egzamin-cpp-train.arff

5.2

egzamin-cpp.arff

	Q	Viewer						
	Relation: egzamin-cpp-weka.filters.unsupervised.attribute							
(No.	1: OcenaC Numeric	2: DataC Date	3: OcenaCpp Numeric	4: Egzamin Nominal			
ı	1	3.5	2016-01	4.0	zdal			
	2	4.5	2016-01	4.0	zdal			
1	3	4.0	2016-01	3.0	nie_zdal			
ı	4	4.5	2016-01	4.5	zdal			
	5	4.0	2016-01	4.5	zdal			
	6	3.5	2016-01	5.0	zdal			
	7	5.0	2016-01	4.0	zdal			
ı	8	3.5	2016-01	3.0	nie_zdal			
	9	4.0	2016-01	5.0	zdal			
	10	5.0	2016-01	4.5	zdal			
	11	5.0	2016-01	3.0	zdal			
	12	5.0	2016-01	3.5	zdal			
	13	4.5	2016-01	3.5	zdal			
	14	3.5	2016-01	3.0	nie_zdal			
	15	5.0	2016-01	3.0	nie_zdal			
	16	4.5	2016-01	5.0	zdal			
	17	3.0	2016-01	3.0	nie_zdal			
	18	4.5	2016-01	4.0	zdal			
	19	5.0	2016-01	5.0	zdal			
	20	4.0	2016-01	2.0	nie_zdal			
	21	5.0	2016-01	5.0	zdal			
	22	5.0	2016-01	3.0	nie_zdal			
	23	5.0	2016-01	5.0	zdal			
	24	5.0	2016-01	5.0	zdal			
1								

egzamin-cpp-train.arff



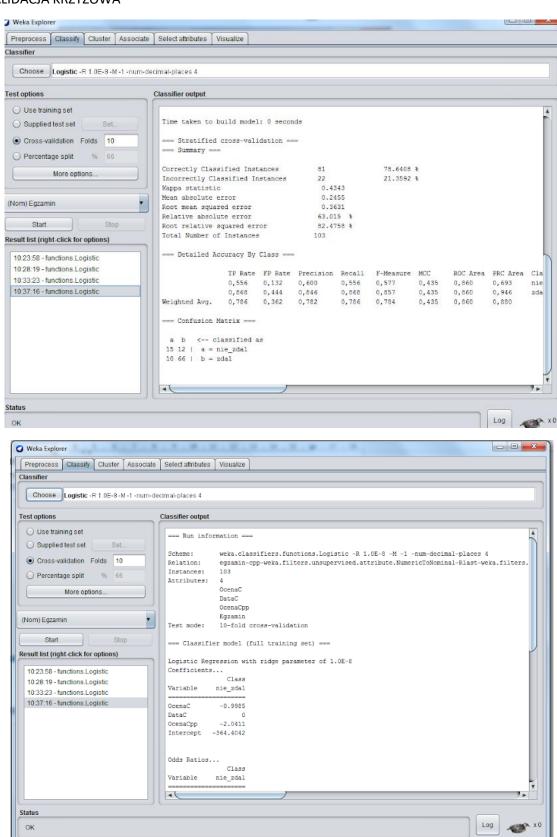
Viewer

Relation: egzamin-cpp-train-weka.filters.unsupervised.attribute.N

No.	1: OcenaC Numeric	2: DataC Date	3: OcenaCpp Numeric	4: Egzamin Nominal
1	3.5	2016-01	4.0	zdal
2	4.5	2016-01	4.0	zdal
3	4.0	2016-01	3.0	nie_zdal
4	4.5	2016-01	4.5	zdal
5	4.0	2016-01	4.5	zdal
6	3.5	2016-01	5.0	zdal
7	5.0	2016-01	4.0	zdal
8	3.5	2016-01	3.0	nie_zdal
9	4.0	2016-01	5.0	zdal
10	5.0	2016-01	4.5	zdal
11	5.0	2016-01	3.0	zdal
12	5.0	2016-01	3.5	zdal
13	4.5	2016-01	3.5	zdal
14	3.5	2016-01	3.0	nie_zdal
15	5.0	2016-01	3.0	nie_zdal
16	4.5	2016-01	5.0	zdal
17	3.0	2016-01	3.0	nie_zdal
18	4.5	2016-01	4.0	zdal
19	5.0	2016-01	5.0	zdal
20	4.0	2016-01	2.0	nie_zdal
21	5.0	2016-01	5.0	zdal
22	5.0	2016-01	3.0	nie_zdal
23	5.0	2016-01	5.0	zdal
24	5.0	2016-01	5.0	zdal

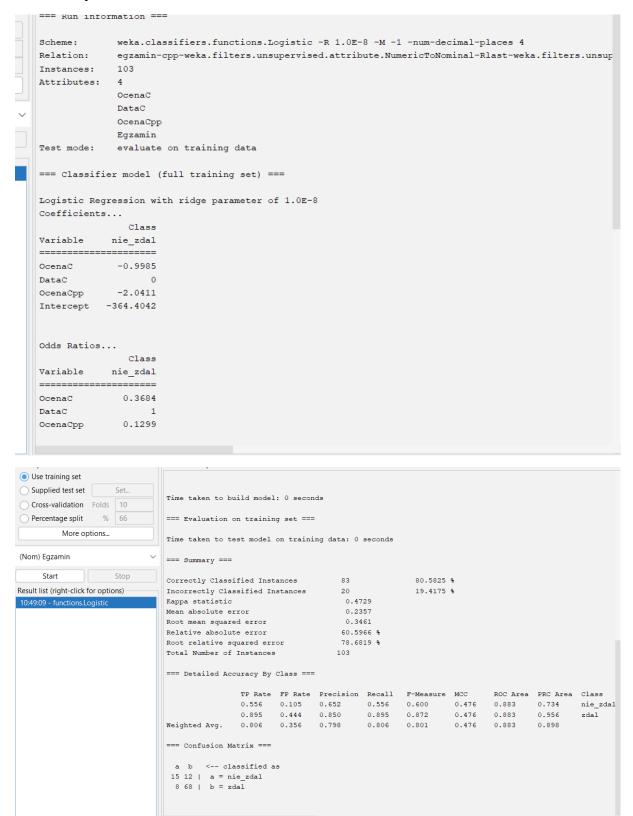
egzamin-cpp.arff

WALIDACJA KRZYŻOWA



Dla walidacji krzyżowej $e^{-0.99} = 0.371 -> 37.1\%$ wzrost oceny o 1, zwiększa szanse zdania egzaminu o 37.1%

ZBIÓR UCZĄCY:



Analiza dla zbioru uczącego:

1. Podaj wzór na hiperpłaszczyznę separującą dane

F(x) = -0.9198 * OcenaC - 2.5471 * OcenaCpp - 1952.6739

- 2. Podaj o ile wzrost/spadek ocen wpływa na szanse zdania/niezdania egzaminu $e^{-0.91}=0.402$ -> 40,2% wzrost oceny o 1, zwiększa szanse zdania egzaminu o 40,2%
 - 3. Jak wpływa na egzamin zmiana daty wpisu zaliczenia?

Data nie wpływa na egzamin.

4. Zinterpretuj wyniki klasyfikacji.

Dokładność zdefiniowana jako $precision = \frac{TP}{TP+FP}$ wynosi 0.65.

Trafność zdefiniowana jako $accuracy = \frac{TP+TN}{TP+FP+FN+TN}$ wynosi 0.80.

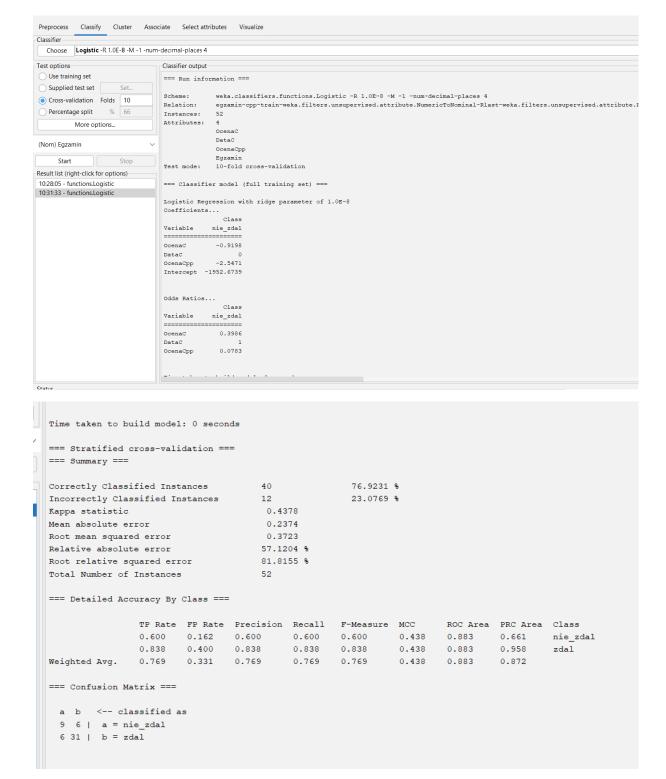
Czułość zdefiniowana jako $recall = \frac{TP}{TP+FN}$ wynosi 0.75.

Miara F1 zdefiniowana jako $F1 = 2 * \frac{precission*recall}{precission+recall}$ wynosi 0.36.

5. Porównaj wyniki testów z użyciem zbioru uczącego i walidacji krzyżowej Porównanie w formie screenshotów wyżej.

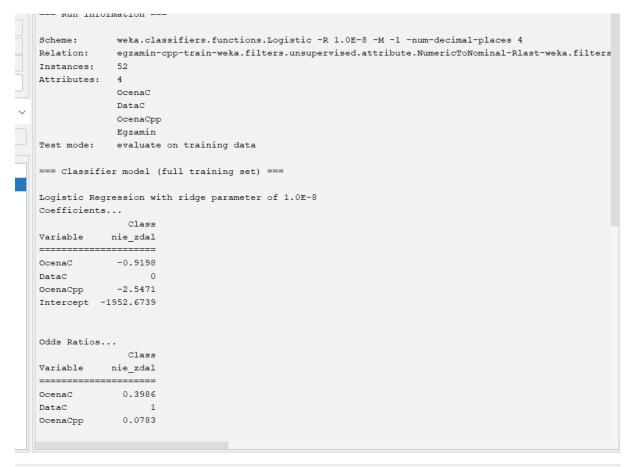
egzamin-cpp-train.arff

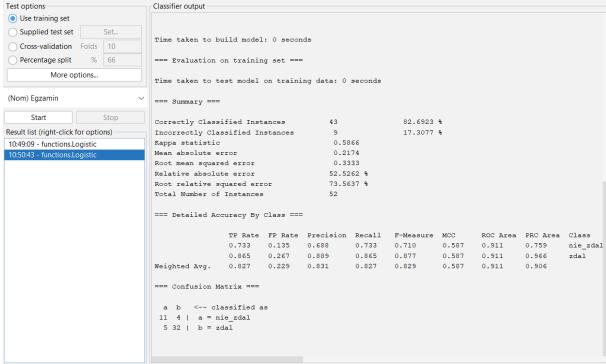
WALIDACJA KRZYŻOWA



Dla walidacji krzyżowej $e^{-0.91}=0.402$ -> 40.2% wzrost oceny o 1, zwiększa szanse zdania egzaminu o 40.2%

ZBIÓR UCZĄCY





Analiza dla zbioru uczącego:

1. Podaj wzór na hiperpłaszczyznę separującą dane

F(x) = -0.9198 * OcenaC - 2.5471 * OcenaCpp - 1952.6739

- 1. Podaj o ile wzrost/spadek ocen wpływa na szanse zdania/niezdania egzaminu $e^{-0.92}=0.398$ -> 39,8% wzrost oceny o 1, zwiększa szanse zdania egzaminu o 39,8%
 - 2. Jak wpływa na egzamin zmiana daty wpisu zaliczenia?

Data nie wpływa na egzamin.

3. Zinterpretuj wyniki klasyfikacji.

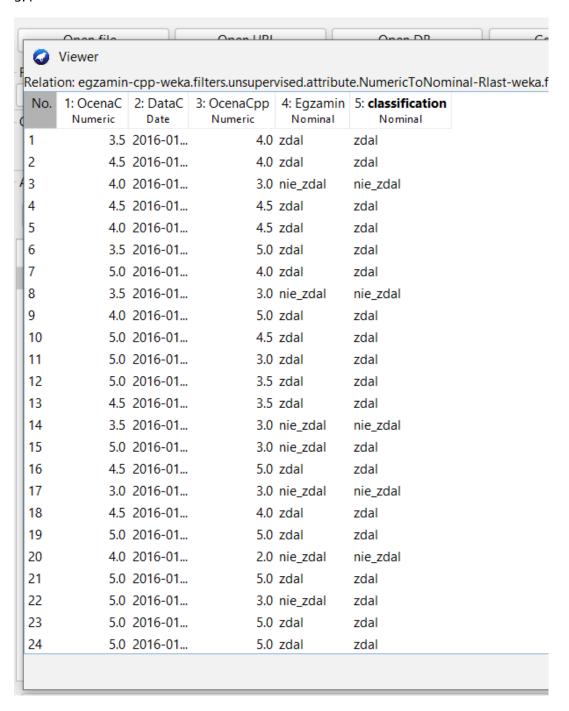
Dokładność zdefiniowana jako $precision = \frac{TP}{TP+FP}$ wynosi 0.69.

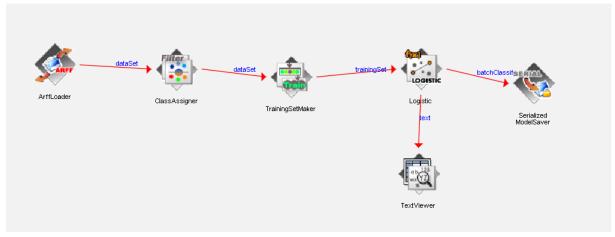
Trafność zdefiniowana jako $accuracy = \frac{TP + TN}{TP + FP + FN + TN}$ wynosi 0.83.

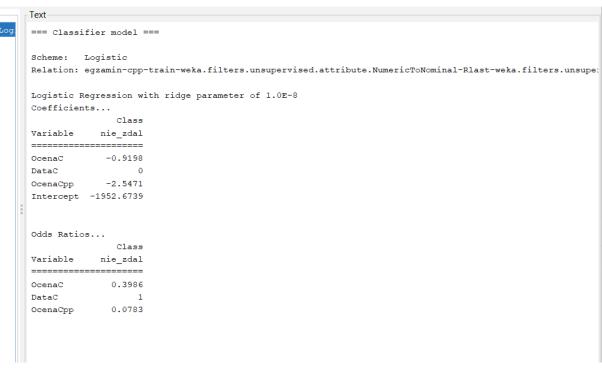
Czułość zdefiniowana jako $recall = \frac{TP}{TP+FN}$ wynosi 1.22.

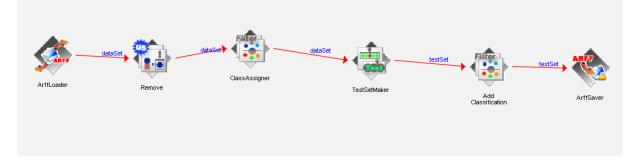
Miara F1 zdefiniowana jako $F1 = 2 * \frac{precission*recall}{precission+recall}$ wynosi 0.38.

4. Porównaj wyniki testów z użyciem zbioru uczącego i walidacji krzyżowej Porównanie w formie screenshotów wyżej.



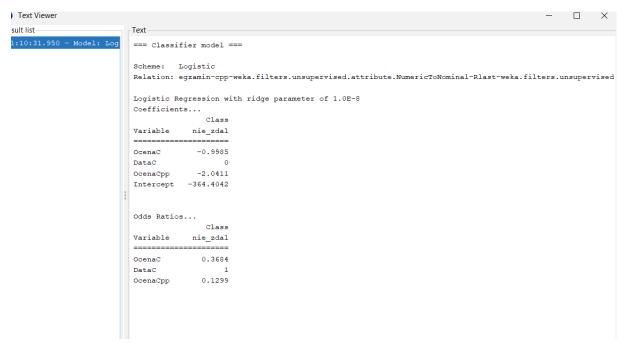






5.6

KW2



KW3

No.	1: OcenaC Numeric	2: DataC Date	3: OcenaCpp Numeric	4: classification Nominal	5: distribution_nie_zdal Numeric	6: distribution_zdal Numeric
	3.0	2016-09	2.0	nie_zdal	0.961375	0.038625
	3.0	2016-09	3.0	nie_zdal	0.763757	0.236243
	3.0	2016-09	3.5	nie_zdal	0.538138	0.461862
	3.0	2016-09	4.0	zdal	0.295734	0.704266
	3.0	2016-09	4.5	zdal	0.131445	0.868555
	3.0	2016-09	5.0	zdal	0.051721	0.948279
	3.5	2016-09	2.0	nie_zdal	0.93792	0.06208
	3.5	2016-09	3.0	nie_zdal	0.662431	0.337569
	3.5	2016-09	3.5	zdal	0.414256	0.585744
0	3.5	2016-09	4.0	zdal	0.203115	0.796885
1	3.5	2016-09	4.5	zdal	0.084132	0.915868
2	3.5	2016-09	5.0	zdal	0.032046	0.967954
3	4.0	2016-09	2.0	nie_zdal	0.901676	0.098324
4	4.0	2016-09	3.0	nie_zdal	0.543614	0.456386
5	4.0	2016-09	3.5	zdal	0.300348	0.699652
6	4.0	2016-09	4.0	zdal	0.133984	0.866016
7	4.0	2016-09	4.5	zdal	0.052814	0.947186
8	4.0	2016-09	5.0	zdal	0.019699	0.980301
9	4.5	2016-09	2.0	nie_zdal	0.847709	0.152291
0	4.5	2016-09	3.0	zdal	0.419618	0.580382
1	4.5	2016-09	3.5	zdal	0.206708	0.793292
2	4.5	2016-09	4.0	zdal	0.085847	0.914153
3	4.5	2016-09	4.5	zdal	0.032737	0.967263
ļ	4.5	2016-09	5.0	zdal	0.012051	0.987949

Open file Open LIDL Onan DD Viewer Relation: egzamin-cpp-train-weka.filters.unsupervised.attribute.NumericToNominal No. 1: OcenaC 2: OcenaCpp 3: Egzamin 4: e Nominal Numeric Numeric Numeric 3.0 0.538138 1 3.5 nie_zdal 2 4.0 3.0 nie_zdal 0.543614 3 4.5 3.0 zdal 0.580382 3.5 3.5 zdal 0.585744 4 3.0 nie_zdal 5 3.5 0.662431 6 5.0 3.0 zdal 0.694997 7 4.0 3.5 zdal 0.699652 8 4.0 zdal 3.0 0.704266 9 0.763757 3.0 3.0 nie_zdal 10 5.0 2.0 nie_zdal 0.771623 11 4.5 3.5 zdal 0.793292 4.0 zdal 12 3.5 0.796885 13 4.5 2.0 nie_zdal 0.847709 3.5 zdal 14 5.0 0.863436 15 4.0 4.0 zdal 0.866016 16 3.0 4.5 zdal 0.868555 17 4.0 2.0 nie zdal 0.901676 18 4.5 4.0 zdal 0.914153 19 3.5 4.5 zdal 0.915868 20 3.5 2.0 nie_zdal 0.93792 21 5.0 4.0 zdal 0.946072 22 4.5 zdal 4.0 0.947186 23 3.0 5.0 zdal 0.948279 24 2.0 nie zdal 0.961375 3.0 25 4.5 4.5 zdal 0.967263 5.0 zdal 0.967954 26 3.5 27 4.5 zdal 5.0 0.97987 28 4.0 5.0 zdal 0.980301 5.0 zdal 29 4.5 0.987949 30 5.0 5.0 zdal 0.992651

```
from sklearn.linear_model import LogisticRegression
   from sklearn.model_selection import train_test_split
   from sklearn.metrics import confusion_matrix, classification_report
   features = ["OcenaC", "DataC", "OcenaCpp", "Egzamin"]
   X = pd.get_dummies(df2[features])
   y = df2['zdal']
   X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3, random_state = 123)
   clf = LogisticRegression()
   clf.fit(X_train,y_train)
   y_pred = clf.predict(X_test)
   print(classification_report(y_test, y_pred))
             precision recall f1-score support
        0.0
                  0.23
                           1.00
                                      0.37
                  0.00
                           0.00
                                      0.00
                                      0.23
                  0.11
                            0.50
                                      0.18
  macro avg
weighted avg
                  0.05
                            0.23
                                      0.08
```

```
def print_formula(weights,intercept,labels,target):
    print(f'{target} = ')
    for i in range(len(weights)):
        print(f'\t{weights[i]: .3g}\t* {labels[i]} +')
        print(f'\t{intercept:.8}')

    print_formula(clf.coef_[0],clf.intercept_[0],df2.columns,'log(odds zdal)')

> 0.0s

log(odds zdal) =
    0.399 * OcenaC +
    -0.109 * DataC +
    1.8 * OcenaCpp +
    -8.5471
```

```
tf.random.set_seed(123)
    model = models.Sequential()
   model.add(layers.InputLayer(input_shape=(X.shape[1],)))
   model.add(layers.Dense(1,activation='sigmoid'))
   model.summary()
   model.compile(optimizer=tf.keras.optimizers.RMSprop(learning_rate = 0.2), loss='binary_crossentropy', metrics=['accuracy'])
   hist = model.fit(X_train,y_train,epochs=10,verbose=1)
 Output exceeds the size limit. Open the full output data in a text editor
 Model: "sequential_1"
 Laver (type)
                     Output Shape
                                        Param #
                     (None, 1)
 Total params: 4
 Trainable params: 4
 Epoch 1/10
              =========] - 0s 2ms/step - loss: 152104119304192000.0000 - accuracy: 0.5000
               =========] - 0s 5ms/step - loss: 99058567369195520.0000 - accuracy: 0.5556
 Epoch 6/10
               :==========] - 0s 4ms/step - loss: 54502568050556928.0000 - accuracy: 0.6944
 3/3 [======
 Epoch 9/10
 Epoch 10/10
 3/3 [=============] - 0s 3ms/step - loss: 110888728368513024.0000 - accuracy: 0.7222
            probs = model.predict(X_test)
            y_pred=y_test
            print(classification_report(y_test, y_pred))
[69]
        ✓ 0.2s
      1/1 [======= ] - 0s 81ms/step
                             precision recall f1-score
                                                                                support
                     0.0
                                                    1.00
                                                                    1.00
                                                                                         7
                                    1.00
                     1.0
                                    1.00
                                                    1.00
                                                                    1.00
                                                                                        24
            accuracy
                                                                    1.00
                                                                                       31
                                    1.00
           macro avg
                                                    1.00
                                                                    1.00
                                                                                       31
      weighted avg
                                    1.00
                                                    1.00
                                                                    1.00
                                                                                       31
```